

GUILHERME GIACOMINI TEIXEIRA

PROJETO INTEGRADO INOVAÇÃO - CIÊNCIA DE DADOS

BALNEÁRIO CAMBORIÚ - SC

2026

GUILHERME GIACOMINI TEIXEIRA

PROJETO INTEGRADO INOVAÇÃO - CIÊNCIA DE DADOS

Trabalho de avaliação da disciplina Projeto Integrado Inovação - Ciência de Dados apresentado como requisito para a obtenção da média no curso Tecnólogo em Ciência de Dados.

Professora: VANICE DALTO

Mentor: JOAO HENRIQUE CORREIA DOS SANTOS

BALNEÁRIO CAMBORIÚ - SC

2026

SUMÁRIO

1 INTRODUÇÃO	4
2 DESENVOLVIMENTO	5
3 RESULTADOS	9
4 CONCLUSÃO	10
5 REFERÊNCIAS	11

1 INTRODUÇÃO

Este relatório técnico apresenta o desenvolvimento do Projeto Integrado de Inovação em Ciência de Dados, cujo objetivo central é propor e demonstrar a viabilidade de uma solução tecnológica para os desafios operacionais de uma empresa nacional de varejo digital. A empresa em questão enfrenta dificuldades crescentes em seus canais de atendimento devido a altos tempos de espera, ausência de classificação automática de chamados, falta de visão estatística de performance e a necessidade latente de mitigação de riscos relacionados à Lei Geral de Proteção de Dados (LGPD).

Para suprir essa demanda, foi projetada e executada uma Prova de Conceito (POC) que unifica conhecimentos de Processamento de Linguagem Natural (NLP), Probabilidade e Estatística, Pesquisa Operacional e Segurança de Dados. O projeto simulou a chegada e o atendimento de mensagens, construiu um modelo classificador automatizado, avaliou a distribuição e frequência estatística dos contatos, e aplicou estratégias de anonimização.

O produto final deste documento detalha a resolução prática do código proposto em ambiente Google Colab, bem como respostas técnicas e fundamentadas às disciplinas correlatas, comprovando a aplicação prática da teoria e a eficiência de uma arquitetura de dados inteligente e segura para processos de negócio do varejo.

2 DESENVOLVIMENTO

A seguir, apresentam-se as análises obtidas a partir da execução do código de simulação proposto para o contexto da empresa de varejo, separadas por disciplina e aplicação prática:

2.1 Análise da Prova de Conceito (Código Colab)

A) NLP

1. Qual categoria teve melhor desempenho no classificador Naive Bayes?

Todas as categorias obtiveram desempenho perfeito no relatório de classificação (Precision, Recall e F1-Score iguais a 1.00). Esse resultado ocorreu devido à forma como os dados fictícios foram gerados: uma lista muito reduzida e repetitiva de frases pré-definidas. Com isso, os dados separados para o teste eram idênticos ou perfeitamente sobrepostos aos vistos no treinamento, não apresentando desafio de generalização para o classificador.

2. Em suas palavras, como funciona a vetorização Bag of Words?

A vetorização Bag of Words (Saco de Palavras) converte textos em formatos numéricos lidos por máquinas. Ela extrai um vocabulário com todas as palavras únicas contidas nos dados e, para cada mensagem, cria um vetor contando a frequência de cada uma dessas palavras. A ordem ou sintaxe da frase é ignorada; a ferramenta se importa unicamente com quais palavras apareceram e quantas vezes.

B) Probabilidade e Estatística

3. Qual categoria teve maior frequência? O que isso indica?

Durante a execução de nossa geração de dados estocásticos, a categoria com maior frequência foi elogio. Em um contexto real de negócios, isso indicaria uma alta satisfação com os serviços prestados, mas, dentro do modelo em questão, indica apenas a variação probabilística e a aleatoriedade selecionando essa variável uma quantidade marginalmente superior de vezes na amostra de 500

mensagens.

4. Interprete o histograma de tempo de espera: é simétrico, assimétrico, disperso?

O histograma gerado pela operação matemática entre as distribuições tendeu à assimetria (mais disperso à direita). Em simulações operacionais reais e em Teoria das Filas, os tempos de espera tendem a ser fortemente assimétricos à direita, concentrando a grande massa de eventos em tempos curtos, com uma cauda longa representando casos atípicos em que o cliente aguardou um período consideravelmente maior devido ao estrangulamento da capacidade do serviço.

C) Pesquisa Operacional

5. O tempo médio de espera é adequado? Como poderia ser reduzido?

O tempo médio na simulação apresentou-se por volta de 2,59 minutos. A adequação está sujeita aos SLAs (Acordos de Nível de Serviço) da empresa. Caso represente um problema - especialmente para a volatilidade do atendimento via chat/WhatsApp -, esse tempo pode ser reduzido otimizando-se o modelo de roteamento de filas, promovendo escalonamento do pessoal nos horários de pico previstos pelas distribuições estatísticas ou inserindo o autoatendimento prévio automatizado.

6. Cite duas ações que podem otimizar o fluxo de atendimento.

Primeira linha de defesa via Chatbot (NLP): Inserir agentes de IA focados em resolver chamados triviais de imediato, reservando os atendentes humanos exclusivamente para as exceções complexas. Além disso, o roteamento especializado para segmentar o tráfego da fila dinamicamente para que assuntos críticos furem a fila comum ou vão diretamente para especialistas, reduzindo o trânsito total da base.

D) Segurança de Dados

7. O que é anonimização?

A anonimização, no contexto corporativo e da LGPD, é a descaracterização técnica de uma informação, removendo elementos vinculantes e impossibilitando, em caráter irreversível, que aquele dado possa identificar direta ou indiretamente uma pessoa física, mantendo entretanto o valor daquele texto como material para

cálculos estatísticos.

8. Quais dados sensíveis podem aparecer em mensagens de clientes?

Nomes completos, CPFs, números de cartões de crédito, dados bancários completos, endereços residenciais, imagens pessoais, e-mails, senhas, além de dados potencialmente sensíveis relativos a saúde e biometria, dependendo da transação.

9. Qual risco existe em armazenar textos sem anonimização?

Armazenar textos na forma bruta incorre no gravíssimo risco de vazamento ou exposição indevida da privacidade. Além de destruir a credibilidade da empresa no mercado, a conduta fere as normas da LGPD, expondo a corporação a multas milionárias (de até 2% do faturamento), obrigações civis de reparação e ao bloqueio total do uso do banco de dados na companhia.

2.2 Resolução de Conceitos Específicos por Disciplina

A) PROCESSAMENTO DE LINGUAGEM NATURAL (NLP)

1. Explique como o processo de pré-processamento textual pode influenciar o desempenho de um classificador de mensagens.

O pré-processamento elimina o ruído e reduz o vocabulário ao mínimo necessário para a extração do contexto analítico. Ele facilita o treinamento do modelo matemático. Exemplo prático: ao remover stop words e unificar sinônimos com stemming, mensagens originalmente distintas como A minha entrega não chegou hoje!! e não recebi entrega transformam-se essencialmente na mesma representação tokenizada, garantindo que o algoritmo de classificação aloque ambas precisamente na mesma caixa.

2. Compare Bag of Words e TF-IDF. Em que situações TF-IDF produz resultados melhores e por quê?

Enquanto o Bag of Words atua com contagem burra e bruta das aparições de palavras, o TF-IDF promove uma penalização estratégica a palavras que aparecem repetitivamente em todos os documentos e não diferenciam os textos. O TF-IDF brilhará na identificação de features em domínios densos, como os dados varejistas

do caso. Ele entenderá que pedido pode ser frequente em quase toda mensagem da loja, reduzindo seu peso preditivo, enquanto exalta o peso definidor do termo ocasional estorno.

3. O Naive Bayes assume independência entre as palavras. Em mensagens curtas de atendimento, essa suposição pode impactar negativamente os resultados?

Sim. Essa premissa ingênua (Naive) pode destruir o significado pragmático na análise de sentimento e intensões curtas. Como ele ignora o encadeamento das palavras (ordem), para ele as frases Não quero devolução, adorei e Quero devolução, não adorei contêm o exato mesmo vetor matemático, o que na vida real representa situações radicalmente opostas.

B) PROBABILIDADE E ESTATÍSTICA PARA ANÁLISE DE DADOS

4. Em um teste A/B aplicado ao tempo de resposta, o grupo A teve média 6,2 min e o grupo B 5,1 min. Como verificar estatisticamente se a diferença é significativa?

Executaríamos um Teste de Hipóteses (tal qual o Teste T de Student para amostras independentes). A Hipótese Nula (H_0) assumiria que as duas médias representam as mesmas realidades, sendo a diferença observada puro acaso. Caso o cálculo do p-valor do Teste T fosse menor do que o nível de significância estabelecido (o habitual alfa de 5%, ou 0,05), rejeitaríamos a Hipótese Nula e inferiríamos de fato que a implantação representou um salto estrutural (estatisticamente significativo).

5. Dado um histograma assimétrico à direita, qual medida de tendência central (média, mediana ou moda) é mais apropriada?

A Mediana. Como a assimetria à direita indica que há poucas ocorrências que puxam a cauda com valores elevadíssimos de tempo, a Média aritmética seria contaminada, parecendo falsamente muito maior do que a realidade experimentada pela enorme maioria dos clientes. A Mediana, indicando o percentil 50, demonstraria mais honestamente o tempo aguardado pelo cliente central.

6. O tempo entre chegadas no call center segue uma distribuição exponencial. O que isso significa em termos de probabilidade?

Isso traduz a famosa Falta de Memória (Markoviana) da distribuição exponencial.

Para os cálculos operacionais de filas, isso garante que o fato de ninguém ter contatado a central há 10 minutos não torna mais provável ou improvável que o próximo contato vá ocorrer nos próximos 3 segundos. É altamente utilizada em pesquisa operacional por representar o caráter naturalmente intermitente.

C) OTIMIZAÇÃO E PESQUISA OPERACIONAL

7. Explique como um modelo de simulação de eventos discretos ajudaria a decidir entre contratar mais atendentes ou investir num chatbot.

O gestor poderia instanciar no software dois cenários distintos espelhando os parâmetros estatísticos do caso real: no Cenário 1, os servidores paralelos (atendentes) aumentam de X para $X+Y$; no Cenário 2, as taxas de chegada são filtradas por um funil anterior (chatbot) que elimina parte da carga. Simular ambas e analisar a métrica final (redução de fila vs aumento de custo) permitiria tomar a decisão corporativa fundamentada financeiramente sem expor a empresa em operação real.

8. Por que modelar com distribuições estatísticas é essencial para simulação e qual a sugestão de melhoria?

Se a empresa adotasse parâmetros de médias estáticas (1 chegada por 2 minutos), jamais veria enfileiramento na simulação. As distribuições estocásticas reproduzem estritamente as imprevisibilidades do mundo fático - as flutuações e picos geradores dos afunilamentos e gargalos. Como melhoria, sugere-se aproveitar os painéis da simulação para identificar gargalos e dimensionar turnos de retaguarda nos momentos corretos.

D) SEGURANÇA DE DADOS

10. Como identificar elementos pessoais automaticamente e os riscos de mantê-los puros?

Com arquiteturas de IA, as empresas constroem rotinas de Named Entity Recognition (NER) unidas a RegEx para capturar padrões sintáticos como de CPFs ou numeração. Se expostas no Data Lake bruto da empresa, uma única engenharia social e exploração de banco poderia expor todo o compliance, acarretando punições drásticas e vazamento de banco.

11. Diferencie pseudonimização de anonimização e explique qual delas é mais adequada para sistemas de chatbot.

A Anonimização destrói a origem (a chave) de forma irreversível; ninguém mais rastreará a pessoa. Já a Pseudonimização mascara o identificador usando tokens

que podem ser rastreados de volta pela empresa de posse das chaves. Em processamentos com Chatbots, a anonimização dos logs textuais soltos e treinamentos de IA garante a paz fiscal, mas os dados estruturados de sessão devem usar pseudonimização para permitir transações.

12. Em um pipeline de NLP, em que etapa a criptografia deve ser aplicada?

A criptografia deve ser aplicada em trânsito (durante o envio e recebimento) e em repouso (nos discos do Data Lake). Contudo, no exato ponto do carregamento na memória RAM para a matriz de NLP, os dados devem estar sem criptografia para não onerar absurdamente a CPU. Neste ponto (memória), deve-se promover a anonimização imediata via ingestão antes da persistência para proteger o aprendizado de máquina.

3 RESULTADOS

Com a execução da Prova de Conceito baseada no código estipulado de simulação Python, assim como do estudo teórico, validou-se a extrema utilidade do emprego da Ciência de Dados na operação central de relacionamento ao consumidor da referida rede de Varejo Digital.

Destacam-se três conclusões principais extraídas e confirmadas na operação:

1. Poder de Interceptação da IA (NLP):

A viabilidade de triagem inteligente via Naive Bayes e NLP confirma que a classificação automática é barata e madura, permitindo ao gestor alocar tempo e recursos humanos exclusivamente naquilo em que a máquina não transita.

2. Previsibilidade e Dimensionamento Matemático (Simulação e Filas):

A compreensão de padrões estocásticos destrói as estratégias primitivas de apenas contratar para diminuir filas. Validou-se a viabilização de testes em Modelos Discretos de Simulação para encontrar o cenário ideal de operação do serviço.

3. Resiliência e Higiene Jurídica nos Dados:

O isolamento e a descaracterização criptografada e anonimizada na modelagem protegem os ativos financeiros da organização e respeitam a intimidade e dados garantidos à sociedade civil pela LGPD.

4 CONCLUSÃO

A realização prática e teórica do Projeto Integrado demonstrou claramente a essência holística do perfil do Cientista de Dados e as responsabilidades adjacentes a ele: não basta construir ou codificar um classificador estatisticamente perfeito se ele colidir com as normas legais de compliance na manipulação daquele dado. A integração proposta nesta Prova de Conceito demonstrou-se robusta.

Modelou-se logicamente o negócio para expandi-lo não usando mera intuição gerencial, mas sim ciência fundamentada em previsibilidade matemática da Pesquisa Operacional e Segurança de Informação perimetral ao algoritmo de IA NLP.

Este trabalho reforça a competência do cientista de dados em prover otimização, escalabilidade inteligente aos processos corporativos sem perder de vista a integridade da arquitetura dos serviços organizacionais.

5 REFERÊNCIAS

KOCH, Ingedore Villaça; ELIAS, Vanda Maria. Ler e escrever: estratégias de produção textual. 2a. ed. - São Paulo: Contexto, 2010

LA TAILLE, Yves de. Moral e ética: dimensões intelectuais e afetivas. Porto Alegre: Artmed, 2007

METCALF, Peter. Cultura e sociedade. (Col. Homem, cultura e Sociedade). São Paulo: Saraiva, 2015

Gestão & Planejamento. FACS Servicos Educacionais S.A. 1999 - ISSN 1516-9103

Revista de Gestão e Projetos 2236-0972